

MATRIZ DE OPTIMIZACIÓN DE COSTOS

Entregable 3 — Entrega Final AI Automation (Coderhouse)

Proyecto	Nexo Digital — Pipeline de Contenidos para Redes Sociales
Modelo IA seleccionado	OpenAI GPT-4o-mini
Alternativas evaluadas	GPT-4o, Claude 3.5 Sonnet, API Batch
Alumna	Ximena Basualdo
Comisión	AI Automation — Prof. Julián Nuñez
Fecha	Septiembre 2026

1. Contexto y Criterios de Selección

El pipeline de Nexo Digital tiene una única tarea de procesamiento IA: generar borradores de contenido para redes sociales a partir de ideas semilla. La selección del modelo se basa en tres criterios: **costo por llamada**, **calidad suficiente para la tarea**, y **velocidad de respuesta**. No se requiere razonamiento complejo, análisis de documentos extensos ni memoria conversacional — es una tarea de generación de texto corto y estructurado.

El volumen estimado del sistema es de **5 a 20 ideas semilla por día**, lo que representa entre 150 y 600 llamadas mensuales a la API. Con este volumen, la diferencia de costo entre modelos se amplifica significativamente.

2. Cuadro Comparativo de Modelos

Criterio	GPT-4o-mini (Seleccionado)	GPT-4o	Claude 3.5 Sonnet	API Batch (OpenAI)
Costo input (por 1M tokens)	USD 0.15	USD 2.50	USD 3.00	USD 0.075 (50% descuento)
Costo output (por 1M tokens)	USD 0.60	USD 10.00	USD 15.00	USD 0.30 (50% descuento)
Calidad para generación de posts	Suficiente. Texto claro y estructurado.	Superior pero innecesaria para esta tarea.	Excelente en texto largo y analítico.	Igual a GPT-4o-mini (mismo modelo, proceso async).
Velocidad de respuesta	Rápida (< 3 seg)	Media (3-8 seg)	Media (3-8 seg)	Lenta (hasta 24h)
JSON mode nativo	Sí	Sí	No nativo (tool_use)	Sí
Max tokens configurados	500	500	500	500
Integración n8n	Nativa (nodo OpenAI)	Nativa (nodo OpenAI)	HTTP Request (requiere config adicional)	HTTP Request (API Batch asíncrona)
Veredicto	SELECCIONADO	Descartado: costo excesivo	Descartado: sin JSON nativo, costo alto	Viable para escala futura (> 1000/día)

Tabla 1 — Cuadro comparativo de modelos IA evaluados. La columna verde indica el modelo seleccionado.

3. Estimación de Costos Mensuales

Se calcula el costo mensual para tres escenarios de volumen, asumiendo un prompt de sistema de ~150 tokens (input) y un output máximo de 500 tokens por llamada:

Escenario	Llamadas /mes	Tokens input estimados	Tokens output estimados	Costo GPT-4o-mini (USD)	Costo GPT-4o (USD)	Ahorro (%)
Bajo (5/día)	150	22,500	75,000	USD 0.05	USD 0.81	94%
Medio (15/día)	450	67,500	225,000	USD 0.15	USD 2.42	94%
Alto (50/día)	1,500	225,000	750,000	USD 0.48	USD 8.06	94%

Tabla 2 — Estimación de costos mensuales por escenario. El ahorro del 94% se obtiene al usar GPT-4o-mini en lugar de GPT-4o.

4. Estrategias de Optimización Implementadas

Estrategia	Implementación	Impacto en costos
Limitación de max_tokens	Configurado en 500 tokens en el nodo OpenAI de n8n. Suficiente para un post de redes sociales.	Evita respuestas largas innecesarias. Reduce el costo de output hasta un 60% vs. sin límite.
Filtro anti-reprocesamiento	Fórmula Airtable: AND({Estado}="Pendiente", {Idea Semilla}!=""). Solo procesa ideas nuevas.	Evita llamadas duplicadas a la API. Ahorro del 100% en re-ejecuciones innecesarias.
JSON mode (structured output)	response_format: json_object en la config del nodo OpenAI.	Elimina la necesidad de parseo manual o re-prompts por formato incorrecto. Ahorra ~10% en reintentos.
Prompt optimizado	System prompt conciso (~150 tokens) con instrucciones claras y formato de salida definido.	Reduce tokens de input. Un prompt de 150 tokens vs. 500 ahorra 70% en costo de input.
Trigger horario (no webhook)	Schedule Trigger cada hora en lugar de webhook en tiempo real.	Agrupar procesamiento. Reduce operaciones de n8n y llamadas API dispersas.

Tabla 3 — Estrategias de optimización de costos implementadas en el pipeline.

5. Plan de Escalabilidad

Si el volumen de Nexo Digital crece más allá de las 1,000 ideas diarias, se recomienda migrar a la **API Batch de OpenAI**, que ofrece un 50% de descuento sobre los precios estándar a cambio de procesamiento asíncrono (hasta 24 horas). Esta opción es viable porque el pipeline no requiere respuesta en tiempo real — el contenido se revisa antes de publicarse.

Volumen	Modelo recomendado	Justificación
1-50 ideas/día	GPT-4o-mini (sincrónico)	Costo mínimo, velocidad inmediata, integración nativa con n8n.
50-500 ideas/día	GPT-4o-mini (sincrónico)	Sigue siendo económico. Costo mensual < USD 5.
500-5,000 ideas/día	GPT-4o-mini vía API Batch	50% de descuento adicional. Proceso asíncrono aceptable para contenido no urgente.
> 5,000 ideas/día	GPT-4o-mini Batch + modelo fine-tuned	Fine-tuning reduce tokens de prompt a ~20. Ahorro adicional del 70% en input.

Tabla 4 — Plan de escalabilidad según volumen de procesamiento.

6. Conclusión

GPT-4o-mini es la elección óptima para el pipeline de Nexo Digital por tres razones fundamentales: (1) su costo es un 94% menor que GPT-4o para la misma calidad de output en tareas de generación de texto corto, (2) soporta JSON mode nativo lo que elimina errores de formato y reintentos, y (3) tiene integración nativa con n8n a través del nodo OpenAI, sin necesidad de configuración HTTP adicional.

El costo operativo estimado del sistema completo es de **USD 0.05 a USD 0.48 mensuales** en consumo de API, dependiendo del volumen. Las estrategias de optimización implementadas (filtro anti-reprocesamiento, max_tokens limitado, prompt conciso, JSON mode) reducen el costo efectivo a una fracción del precio de catálogo.